曾浩男

求职意向：AI 应用开发工程师 / Agent 开发工程师

电话：13392957547 | 邮箱：haonanzeng98@foxmail.com

教育背景

伦敦玛丽女王大学 | 硕士 • Computer Games（游戏开发） | 2021.09 – 2022.09

华南农业大学+英国邓迪大学 | 本科（2+2）• 计算机科学与技术/Applied Computing | 2017.09 – 2021.06

工作经历

金伯爵供应链有限公司 | 运营转 AI 应用开发 | 2022.12 – 至今

- 前期负责电商平台日常运营，包括商品管理、运营与销售数据分析，积累了扎实的供应链与电商业务理解。
- 后期依托计算机专业背景和专业能力，主导了 AI 语音智能客服等应用开发、完成了从业务岗位向 AI 应用开发的转型实践。

项目经历

AI 实时语音对话智能客服：

- 使用 Prompt Pilot 进行提示词版本管理，搭建自动化评测体系用于版本效果对比；基于负样本迭代重构提示方案，沉淀高质量指令数据，支撑后续模型精调，提升模型回复准确度与一致性。
- 采用自定义标识符对知识库进行切片，解决语义截断问题。构建 Metadata 标签前置过滤。应用 Int8 量化，向量存储空间降低 75%。
- 针对 AI 语音场景通过降维与精简 Limit 策略，引入 base-rerank 轻量模型，落地 HNSW_HYBRID 混合检索，在保持语义理解的同时显著提升专有名词的命中率，检索速度提升 4 倍。
- 构建高效率 AI 集成开发环境，利用 Swagger UI 抽象核心业务逻辑实现可视化模型评测，提升了开发的工程迭代效率。

RAG 知识库智能问答服务：

- 父子双层切片机制，平衡检索精度与文本完整性，增强知识库检索准确性的同时减少 chunk 的上下文损失。
- 极致优化 LLM 推理链路性能，通过固定 RAG 检索片段排序、合并 System Prompt 消息体等手段，深度触发模型前缀缓存（Prefix Caching）与 KV Cache 机制，将复杂 RAG 场景下的首字延迟大大压缩。
- 实现基于内联引用的答案溯源，agent 中以 *[N]* 标注原文出处。通过自定的 LangGraph tools_node 添加了注册表保证编号跨多轮工具调用稳定，并过滤掉幻觉引用。

专业技能

- 后端开发：Python、FastAPI、SSE、Git
  AI / LLM：LangChain、LangGraph、RAG、Prompt 工程、LLaMA-Factory 模型微调
  Vibe Coding：Claude Code